

SPRAWOZDANIE Z PROJEKTU BIG DATA

Temat: Przewidywanie opóźnień lotów lotniczych na podstawie danych pogodowych i historycznych rozkładów z wykorzystaniem Apache Spark.

Wykonawcy:

Szymon Muszyński, numer indeksu 245883,

Dominik Klimczak, numer indeksu 245842

1. Cel projektu i założenia badawcze

1.1 Cel i tezy

Celem projektu było stworzenie systemu analitycznego klasy Big Data, zdolnego do przewidywania ryzyka opóźnienia startu samolotu (Departure Delay). Projekt miał na celu sprawdzenie, w jakim stopniu czynniki atmosferyczne w połączeniu z danymi operacyjnymi (przewoźnik, natężenie ruchu) wpływają na punktualność lotów w USA.

Teza: "Wykorzystanie rozproszonego przetwarzania danych oraz algorytmów uczenia maszynowego pozwala na skuteczną predykcję opóźnień lotniczych, przy czym czynniki operacyjne mają większy wpływ niż umiarkowane zjawiska pogodowe"

1.2 Metodyka

W projekcie założono wykorzystanie platformy **Apache Spark** ze względu na wolumen danych (zbiór rzędu 14 milionów rekordów). Do analizy predykcyjnej wykorzystano bibliotekę **Spark MLlib**. Proces badawczy obejmował:

- Analizę statystyczną i eksploracyjną danych.
- Budowę potoków przetwarzania (Pipelines) dla automatyzacji procesu.
- Porównanie algorytmów klasyfikacyjnych: **Random Forest** (Las Losowy) oraz **Gradient Boosted Trees** (Drzewa Podbijane Gradientowo).

1.3 Architektura systemu i stos technologiczny

Projekt został zaprojektowany w oparciu o nowoczesną architekturę mikroservisów, co pozwala na separację procesów obliczeniowych od warstwy prezentacji. Po przeprowadzeniu fazy eksperymentalnej w środowisku Google Colab, gdzie przetestowano różne warianty algorytmów uczenia maszynowego, jako rozwiązanie

produkcyjne wybrano model Gradient Boosted Trees (GBT) ze względu na jego wysoką skuteczność w klasyfikacji danych tabelarycznych.

System składa się z następujących komponentów zintegrowanych w środowisku Docker:

1. **Warstwa Prezentacji (Frontend):** Prosty i responsywny interfejs użytkownika zbudowany w bibliotece **React.js**. Pozwala on na interaktywne wprowadzanie parametrów lotu oraz warunków pogodowych, a dzięki dynamicznemu pobieraniu metadanych (listy lotnisk i przewoźników) bezpośrednio z wytrenowanego modelu, eliminuje błędy wprowadzania danych.
2. **Warstwa API (Backend):** Serwis oparty na frameworku **FastAPI (Python)**. Pełni on rolę pośrednika (producenta komunikatów), który przyjmuje żądania od użytkownika i przekazuje je do szyny danych, zapewniając asynchroniczność i wysoką przepustowość.
3. **Strumieniowa Szyna Danych (Apache Kafka):** Kluczowy element architektury wykorzystujący **Kafkę** oraz **Zookeepera**. Służy do przesyłania strumieni danych pomiędzy API a silnikiem predykcyjnym. Takie podejście umożliwia skalowanie systemu i obsługę dużej liczby zapytań w czasie rzeczywistym.
4. **Silnik Analityczny (Apache Spark MLlib):** Główny moduł predykcyjny działający w środowisku **Apache Spark**. Składa się z dwóch etapów:
 - **Trainer:** Kontener odpowiedzialny za pobranie zbioru danych (Kaggle), czyszczenie danych, inżynierię cech (StringIndexing, VectorAssembler) oraz trening modelu GBT.
 - **Spark-ML Service:** Konsument Kafki, który w trybie ciągłym nasłuchuje nowych zapytań, wykonuje predykcję na podstawie załadowanego modelu i odsyła wynik z powrotem do API.
5. **Konteneryzacja (Docker & Docker Compose):** Całość rozwiązania została zamknięta w kontenerach, co zapewnia pełną powtarzalność środowiska. API oraz Frontend są wyeksponowane na zewnątrz (mapowanie portów), co umożliwia łatwe testowanie i wdrożenie aplikacji w dowolnym środowisku chmurowym.

Dzięki takiemu podejściu, system nie tylko realizuje zadanie predykcji opóźnień, ale stanowi gotowy wzorzec architektury **Big Data**, zdolny do przetwarzania danych w czasie zbliżonym do rzeczywistego.

2 Dobór i charakterystyka danych

2.1 Źródło i organizacja danych

W projekcie wykorzystano zbiór danych *Flight Ontime Reporting with Weather*, zawierający kompletne dane o operacjach lotniczych w USA. Zbiór łączy historyczne logi z systemów lotniskowych z odczytami meteorologicznymi.

Format i Struktura: Dane są przechowywane w formacie .csv. Struktura katalogów jest partycjonowana według kodu lotniska wylotu (zgodnie z widoczną strukturą plików: ATL.csv, JFK.csv, ORD.csv itd.). Taka organizacja danych ułatwia przetwarzanie rozproszone w Apache Spark, umożliwiając równoległe wczytywanie plików.

2.2 Opis atrybutów

Zbiór danych łączy informacje operacyjne z danymi meteorologicznymi. Zbiór danych zawiera następujące atrybuty:

Kolumny opisowe:

- Time: Data i godzina planowanego wylotu (podstawa do ekstrakcji cech sezonowych).
- Origin / Dest: Kody IATA lotniska wylotu i przylotu. Kolumny opisujące
- Carrier: Kod przewoźnika lotniczego (kluczowa zmienna kategoryczna w modelu).
- DepDelayMinutes: Różnica w minutach między planowanym a rzeczywistym czasem wylotu (zmienna celu - Target).

Dane meteorologiczne:

- Tempature (Temperatura): Podana w stopniach Fahrenheita.
- Wind_Speed / Wind_Gust: Prędkość wiatru i porywy (w milach na godzinę - mph).
- Precipitation: Opady w ciągu ostatniej godziny (w milimetrach).
- Ice_Accretion_3hr: Przyrost oblodzenia (w milimetrach) – zmienna rzadka, ale krytyczna.
- Visibility: Widoczność (w milach).
- Altimeter_Pressure / SeaLevelPreasure: Ciśnienie atmosferyczne.

Szczegółowe przyczyny opóźnień:

- CarrierDelay: Opóźnienie z winy przewoźnika.
- WeatherDelay: Opóźnienie spowodowane warunkami pogodowymi.
- NASDelay: Opóźnienie systemu kontroli przestrzeni powietrznej.
- LateAircraftDelay: Opóźnienie wynikające z późnego przylotu maszyny.

2.3 Analiza jakościowa zbioru i braki danych

Przeprowadzono analizę danych jakości danych, aby zidentyfikować konieczne kroki czyszczenia.

Column	Missing_Count	Missing_Percentage
CancellationReason	14162151	97.71014892
LateAircraftDelay	11336160	78.21254566
NASDelay	11336160	78.21254566
SecurityDelay	11336160	78.21254566
CarrierDelay	11336160	78.21254566
WeatherDelay	11336160	78.21254566
DepDelayMinutes	321246	2.216400214
Cancelled	0	0
Dest	0	0
Origin	0	0
Time	0	0
Carrier	0	0
Delayed	0	0
Temperature	0	0
Feels_Like_Temperature	0	0
Altimeter_Pressure	0	0
Sea_Level_Pressure	0	0
Visibility	0	0
Wind_Speed	0	0
Wind_Gust	0	0
Precipitation	0	0
Ice_Accretion_3hr	0	0

Tab. 1. Zestawienie brakujących wartości w zbiorze danych

Dane pogodowe i operacyjne: KOMPLETNE - Kolumny takie jak Time, Origin, Carrier oraz wszystkie zmienne pogodowe (Temperature, Wind_Speed, etc.) posiadają **0 brakujących rekordów**. Oznacza to wysoką jakość danych wejściowych dla modelu predykcyjnego.

Specyfika kolumn opóźnień: Kolumny szczegółowe (CarrierDelay, WeatherDelay, LateAircraftDelay) posiadają ok. 78% wartości brakujących (null). Jest to zjawisko naturalne i logiczne – rekordy te są wypełniane tylko w przypadku wystąpienia opóźnienia. Brak wartości oznacza w tym kontekście brak opóźnienia z danej przyczyny.


Anulowania: Kolumna CancellationReason posiada blisko 97.7% braków, co potwierdza, że zdecydowana większość lotów w zbiorze odbyła się (nie została odwołana).

3. Ekstrakcja, transformacja i modelowanie

Proces budowy modelu przebiegał w trzech iteracjach. Każda kolejna iteracja wynikała z wniosków wyciągniętych z analizy wyników poprzedniej, co pozwoliło na stopniowe zwiększanie skuteczności predykcji.

3.1. Uzasadnienie doboru cech


Przed rozpoczęciem modelowania zweryfikowano, co jest główną przyczyną opóźnień, aby dobrać odpowiednie cechy wejściowe.



Rys. 1. Sumaryczny czas opóźnień w podziale na przyczyny.

Wykres ten (Rys. 1) był kluczowy dla dalszych prac. Wykazał on, że **pogoda (WeatherDelay) jest dopiero 4. przyczyną opóźnień**. Dominują opóźnienia zależne od przewoźnika (CarrierDelay) oraz opóźnienia wtórne (LateAircraft). **Wniosek:** Model oparty wyłącznie na prognozie pogody będzie nieskuteczny. Konieczne jest uwzględnienie w modelu informacji o przewoźniku (Carrier).

Dodatkowo zbadano korelację zmiennych numerycznych:



Rys. 2. Macierz korelacji zmiennych.


Selekcja cech: Na podstawie powyższej macierzy korelacji (Rys. 2) podjęto decyzję o redukcji liczby zmiennych pogodowych w celu uniknięcia zjawiska współliniowości oraz usunięcia szumu informacyjnego:

1. Redukcja zmiennych skorelowanych: Zauważono niemal idealną korelację (0.99) między Temperature a Feels_Like_Temperature. Użycie obu zmiennych wprowadziłoby redundancję, dlatego do modelu wybrano tylko **Temperature** jako odczyt bezpośredni z czujników. Podobną decyzję podjęto dla par ciśnienia (Altimeter_Pressure vs Sea_Level_Pressure), usuwając obie ze względu na ich znikomą korelację ze zmienną celu (DepDelayMinutes).


2. Eliminacja zmiennych o niskim wpływie: Parametry takie jak Visibility wykazały w fazie eksploracji (EDA) marginalny wpływ na opóźnienia w analizowanym zbiorze danych, dlatego zostały pominięte w finalnym modelu GBT na rzecz cech o wyższej istotności, takich jak **Wind_Gust** (Porywy wiatru) oraz **Precipitation** (Opady).

3. Skupienie na zjawiskach ekstremalnych: Do modelu włączono zmienną **Ice_Accretion_3hr** (Oblodzenie) oraz **Wind_Gust**, ponieważ w lotnictwie to właśnie nagłe i ekstremalne zjawiska pogodowe, a nie średnie warunki klimatyczne, są najczęstszą przyczyną wstrzymania operacji lotniczych (tzw. Ground Stop).

3.2 Analiza rozkładów i wartości odstających Cechy związane z opóźnieniami (DepDelayMinutes, CarrierDelay, WeatherDelay, NASDelay, SecurityDelay, LateAircraftDelay) wykazują silnie skośne rozkłady w prawo z licznymi, znaczącymi wartościami odstającymi. Na przykład, DepDelayMinutes miało średnią około 16 minut, ale maksymalną wartość 3695 minut. CarrierDelay osiągnęło 3221 minut, a WeatherDelay 1805 minut. Te wartości reprezentują autentycznie ekstremalne zdarzenia opóźniające.



Rys. 3. Rozkład oraz wykres pudełkowy opóźnienia przewoźnika.




Rys. 4. Rozkład oraz wykres pudełkowy opóźnienia spowodowanego pogodą.


Warunki pogodowe (Wind_Speed, Precipitation, Visibility, Ice_Accretion_3hr) również pokazały rozkłady skośne w prawo z wyraźnymi wartościami odstającymi, takimi jak Wind_Speed z maksimum 281.94 i Precipitation z maksimum 82.3, co wskazuje na poważne zjawiska pogodowe.

Rozkłady Temperature i Feels_Like_Temperature były bardziej symetryczne, ale zawierały łagodne, fizycznie wiarygodne wartości odstające.

Cechy czasowe (DayOfWeek, HourOfDay, Month) wykazały dyskretne, często cykliczne rozkłady, a nie typowe wartości odstające.



Rys. 5. Rozkład oraz wykres pudełkowy oblodzenia lotniska przed wylotem.



Rys. 6. Rozkład oraz wykres pudełkowy prędkości wiatru.

3.3 Analiza zbalansowania klas

Zbalansowanie zmiennej docelowej (Delayed):

Zmienna docelowa Delayed wykazała umiarkowaną nierównowagę klas: 39.04% lotów było opóźnionych (True, 5,659,143 rekordów), podczas gdy 60.96% było na czas (False, 8,834,900 rekordów).

4. Modelowanie i ewaluacja

4.1 Iteracja 1: Model bazowy (Pogoda + czas)

W pierwszym podejściu zbudowano model bazowy, aby ustanowić punkt odniesienia.

Cechy: Miesiąc, Godzina, Temperatura, Wiatr, Opady, Widoczność.

Algorytm: Random Forest Classifier (40 drzew).

Technika: Zastosowano ważenie klas (classWeight), aby zniwelować dysproporcję między lotami o czasie a opóźnionymi.

Wynik: AUC: ~0.6725


Wnioski: Model osiągnął przeciętny wynik. Analiza ważności cech wykazała, że pogoda ma umiarkowany wpływ, a najważniejsza była Godzina lotu. Potwierdziło to hipotezę z fazy EDA, że brakuje kluczowych danych operacyjnych.

4.2 Iteracja 2: Model rozszerzony o dodanie przewoźnika

W drugiej iteracji, zgodnie z wnioskami z Rys. 1, włączono do modelu informację o linii lotniczej.

Zmiany: Dodano kolumnę Carrier. Przetworzono ją za pomocą StringIndexer (zamiana nazw linii na liczby).

Algorytm: Random Forest Classifier.



Rys. 7. Średnie opóźnienie w zależności od przewoźnika

Wynik: AUC: ~0.6935 (Wzrost o ~0.02)

Wnioski: Poprawa jakości. W rankingu ważności cech Carrier wskoczył na 2. miejsce (wpływ 18%), ustępując jedynie Godzinie (44%). Model zaczął "rozdzielić", że niektóre linie lotnicze (np. JetBlue) mają tendencję do częstszych opóźnień.

4.3 Iteracja 3: Model GBT

W tym podejściu zdecydowano się na zmianę algorytmu na bardziej zaawansowany oraz dodanie informacji o trasie (Lotnisko Docelowe - Dest), ponieważ pogoda w miejscu przylotu również wpływa na start.

Zmiana Algorytmu: Zastosowano **Gradient Boosted Trees (GBT)**. Jest to algorytm uczący się sekwencyjnie (poprawiający błędy poprzednich drzew), który zazwyczaj osiąga lepsze wyniki niż Random Forest na trudnych danych.

Wynik finalny: AUC: ~0.7048

Wnioski: Przekroczono próg 0.70 AUC. Model stał się stabilny i uwzględniał pełny kontekst lotu (Skąd? Dokąd? Kim? O której? Jaka pogoda?).

4.4 Iteracja 4: Zastosowanie ważenia klas

W ostatnim podejściu adresowano problem nierównowagi klas zidentyfikowany w fazie EDA. Analiza zbioru treningowego wykazała, że loty opóźnione stanowią jedynie 21.26% (ok. 2,4 mln) wszystkich rekordów, podczas gdy loty o czasie to 78.74% (ok. 8,9 mln), co mogło negatywnie wpływać na czułość modelu.


Zmiany: Zastosowano mechanizm ważenia klas (Class Weighting) w celu wyrównania szans predykcyjnych. Obliczono wagi odwrotnie proporcjonalne do częstotliwości występowania klas:

- Klasa 0.0 (Brak opóźnienia): waga **0.6350**
- Klasa 1.0 (Opóźnienie): waga **2.3523** (ponad 3-krotnie wyższa waga kary za błąd).

Algorytm: Gradient Boosted Trees (GBT) z uwzględnieniem kolumny wag (*weightCol*).

Wynik: AUC: **0.7049** (Minimalny wzrost z poziomu 0.7048).

Wnioski: Zastosowanie wag przyniosło marginalną poprawę wskaźnika AUC. Oznacza to, że model już w poprzedniej iteracji (bez wag) skutecznie wyłapywał wzorce opóźnień dzięki sile algorytmu GBT. Mimo braku skokowego wzrostu AUC, model ważony jest bardziej pożądany w zastosowaniu produkcyjnym, ponieważ "koszt" nieprzewidzenia opóźnienia jest traktowany priorytetowo.



Rys. 8. Ważność cech modelu finalnego

5. Wnioski końcowe

Projekt zakończył się sukcesem, potwierdzając postawioną na wstępie tezę. Stworzony system osiągnął skuteczność **AUC > 0.70**, co dla danych rzeczywistych jest wynikiem satysfakcjonującym.

Kluczowe wnioski z analizy modelu:

1. **Czas jest najważniejszy (Miesiąc ~24%, Godzina ~19%):** Największe ryzyko generuje "efekt kuli śnieżnej" – opóźnienia kumulują się w godzinach wieczornych oraz w szczytach sezonowych (zima/wakacje).
2. **Czynnik Operacyjny (Przewoźnik ~17%, Trasa ~14%):** Wybór linii lotniczej oraz lotniska ma większe znaczenie niż przeciętna pogoda. Model wykrył, że niektóre linie radzą sobie znacznie gorzej operacyjnie.
3. **Rola Pogody:** Umiarkowane warunki (temperatura, wiatr) mają mniejszy wpływ (<10%). Dopiero silne zjawiska (intensywne opady, porywy wiatru), które dodano w ostatniej iteracji, są silnym sygnałem ostrzegawczym dla modelu.
4. **Odporność na niezbalansowanie klas:** Zastosowanie techniki ważenia klas (Class Weighting) poskutkowało jedynie marginalnym wzrostem skuteczności (AUC z 0.7048 do 0.7049). Świadczy to o dużej sile algorytmu Gradient Boosted Trees, który nawet przy nierównym rozkładzie danych (21% lotów opóźnionych) potrafi skutecznie identyfikować wzorce opóźnień, nie wymagając sztucznej ingerencji w wagi próbek.

Podsumowanie: Zastosowanie technologii Apache Spark pozwoliło na przetworzenie pełnego zbioru 14 milionów rekordów. Ewolucja modelu od prostego lasu losowego do zaawansowanych drzew gradientowych (GBT) pozwoliła na zwiększenie precyzji predykcji i pełniejsze zrozumienie zjawiska opóźnień lotniczych.